情報科学応用実習Ⅱ テキスト

「バイオ分野のデータベースの統合的な利用」

2007年度版

長 浜 バ イ オ 大 学 バイオサイエンス学部

バイオ分野のデータベースの統合的な利用

ゲノムの塩基配列は、人類の共通の財産として全世界の人々が利用できる形にデータベース化されています。各国の公的な資金で塩基配列は解読されたものは勿論ですが、個々の企業が配列を解読したものであっても、それを使って論文発表を行う際には、その塩基配列を国際 DNA データバンク (DDB J/EMBL/GenBank) のいずれかに登録する必要があります。各データバンクは相互にその配列を共有して、全世界に公開しています。世界中の誰でもインターネットを利用して、どの機関からでも家からでも自由にこのデータを参照し、研究し利用することが可能です。ゲノムの塩基配列は大量な情報であり、それを解析し利用するには計算機の利用が不可欠ですが、多様な配列解析や配列検索等を、国際 DNA データバンク (例えば DDB J) の高機能な計算機を利用して、インターネットを介して自由に行えます。バイオ分野の研究開発において、データベースの利用は益々その重要性を増しています。

バイオ分野には、DNA 塩基配列のデータベース以外にも多様なデータベースが存在します。例えば、色々な生物種についての特徴や形態を収録したデータベース、それらの突然変異体を収録したデータベース、多様な病気とそれに関係する遺伝子に関するデータベース、遺伝子クローンや突然変異体を含む生物材料の配布機関を収録したデータベースもあります。これらのデータベースはバイオの研究開発だけでなく、バイオ分野の産業利用においても重要になります。

バイオ分野のデータベースは多数作成されているので、多様なデータベースの内容を収録したデータベース(データベースのデータベース)も作成されています。現在利用可能なバイオ分野データベース類を紹介する目的で、本実習ではこのデータベースのデータベースを利用します。バイオ分野のデータベースは英語で記載されていることが一般的ですが、中には最新の知識を日本語で紹介した例もあります。ここでは、日本語の説明があるデータベースの例を最初に紹介します。バイオ分野のデータベースのデータベースとして、WINGproを使用します。WINGproは、長浜バイオ大も参画している「文部科学省のライフサイエンス分野の統合データベース整備事業」の一環として運営されています。バイオ分野の多様なデータベースの内容を理解し、その有用さを知ってもらうこと、複数のデータベースを統合的に利用することの重要さを認識してもらうことが可能になります。あわせて、バイオ分野のデータベースは、大きな機関が作成するだけではなく、個々の研究者やそのグループ、さらには産業分野での活動の成果の集積として作成された、特徴のある例が多いことにも気付くことでしょう。皆さんも、このような特徴のあるデータベースを作成する機会に出会うこともあると思います。長浜バイオ大の3回生や4回生の教育活動のなかでも、特徴のあるデータベースを作成し、国内外へ発信する予定です。

WINGpro(データベースポータルサイト)の利用。

ポータルとは港(port)から派生した言葉で、多数のデータベースについての情報が収集、整理、分類されており、これらのデータベースを利用する上での玄関や入り口に相当します。

画面1は WINGpro のメイページです (http://wingpro.lifesciencedb.org/)。 検索サイト Google 日本 (http://www.google.co.jp/)で、"WINGpro" を検索項目として検索しても、検索結果に メインページ WINGpro が表示されますので、そちらをクリックしても表示されます。

左側の**コンテンツ**の欄の**データベース一覧**(WINGpro 収録)をクリックすると、WINGpro に 収録されている個々のデータベースの特徴や提供機関や国別情報等に関する日本語での説明文が得られます (画面 2)。



この一覧表では、大半のデータベース類が、数字、次に A, B, C... の順番に並べられています。



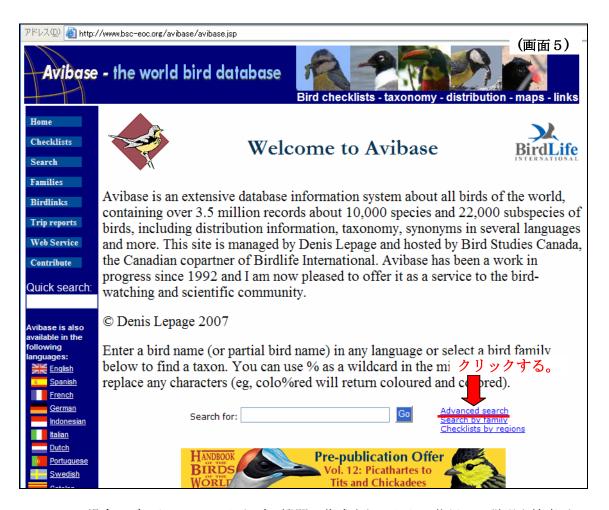
まず親しみやすい**全世界に生息する鳥に関するデータベース Avibase** を例に、データベースの内容を参照します。画面 2 を下にスクロールして、**画面 3** の**名称欄**の **Avibase** (The World Bird Database)の下の Wing pro の文字をクリックします。

				(画面3)
Avibase (The World Bird Database) 提供サイト @ Wing pro	全世界に生息する鳥に関するデータベース。 鳥の分布、分類、同義語、各言語での表記法(日本語もある)等を 見ることができる。 分布は世界地図(画像)で見ることができる。 鳥の調査のために世界各地を訪れた際の記録も公開されている。	Bird Studies Canada	カナダ	Webアプリケ ーションによ る検索および 結果の閲覧。
Barcode of Life 提供サイト iP Wing pro	クリックする。 DNAパーコード(生物種を特徴付ける短いDNA配列)のデータベース.	The Consortium for the Barcode of Life (CBOL)	カナダ	Web アプリ ケーションに よるデータの 閲覧.
	岡山大学の資源生物科学研究所のオオムギの生殖細胞とゲノム解析に関する情報が入っている。文部科学省のナショナルバイオリソースプロジェクト(NBRP; National Bioresource Project)の支援を受けて設計された。			
	<1> Barley Germplasmデータベースオオムギの生殖細胞に関する情報が入っている。元々は岡山大学名誉教授のDr. Ryuhei Takahashi監督の下, 1983年にCatalog of barley germplasm preserved in Okayama Universityとして構築された。	岡山大学資源生物科		

すると、Avibase に関する日本語の説明文が得られます(画面4)。

画面右側にある 提供サイトのURLをクリックすると、実際の Avibase データベースへ入れます (画面 5)。



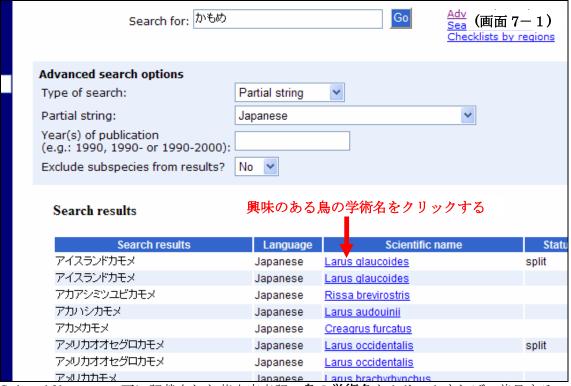


Avibase の場合、データベースはカナダの機関で作成されており、英語での説明や検索が中心になります。しかしながらこのデータベースは世界の広い国での利用を想定しており、画面 5 の Search for: の右横の空白欄の GO の右隣の Advanced search をクリックすると、画面 6 に変わり、その Partial string: All languages の欄を Japanese に変更すると、日本語を使用した検索が可能になります。





画面 7 の Search for: の横の空白欄へ**かもめ**を入力し、[Go]をクリックすると、**画面 7** の下の部分に **Search results** として検索結果が表示されます(**画面 7-1**)。

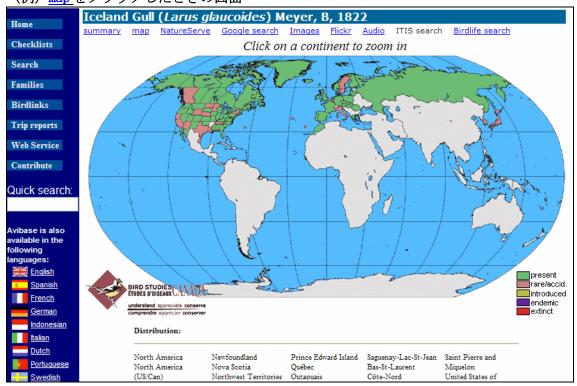


Scientific name の下に記載された英文字表記の**鳥の学術名**をクリックすれば、着目する 鳥の写真や各国での呼び名(other synonyms)が得られます(画面8)。

画面8 の鳥の写真の上の行に記載された <u>summary</u> (説明) や <u>map</u> (生息域) や <u>images</u> (写真) をクリックすることで、より詳細な情報を得ることが可能になります。



(例) map をクリックしたときの画面



レポート課題 1) Avibase を用いて、かもめ以外の鳥を自分で設定して、その鳥の学術名と map (生息域) と image (写真)を記載せよ。

全世界に生息する鳥に関するデータベースのように、最近のバイオ分野でのデータベースの中では、画像を中心にしたものもあり、自然の美しさや分子の複雑な構造を知るこ

とが可能になります。画面 2 をスクロールして**アサガオのホームページ**に入れば、アサガオ (Ipomoea nil) の突然変異系統情報や、突然変異遺伝子のリストやその写真が参照できます。

WINGpro には多数のバイオ分野のデータベースが収録されていますので、自分の関心のあるデータベースを効率的に検索する必要があります。WINGpro の初期画面 (http://wingpro.lifesciencedb.org/) (画面 1) に戻って、左欄のコンテンツの欄のディレクトリについて をクリックすると、画面 9 が現れます。





この画面では、データベースを**構築型分類、物質概念による分類、構造概念による分類** 等のデータベース分野での専門的な視点からの分類がなされていますが、自分の関心のあるデータベースを容易に探し出せます(但し、現時点では、残念ながら、**データベース一覧** の一部しか分類されていないので注意が必要です)。

レポート課題 2) 物質概念による分類の DNA と RNA の各々の項目について、何種類のデータベースが収録されているかを記載せよ。

物質概念による分類の下の**タンパク質(画面 9)**をクリックすると、タンパク質に関するデータベースの一覧が得られます**(画面 10)**。

x					(画面 10)		
名称	概要	開発機関	国名	型分類	対象	4	
GTOP 提供サイト @ Wing pro	Protein fold predictions from genome sequences	遠伝研DDBJ	Japan	プログラム	タンパク質, 立 ・ 体構造		
PMD 提供サイト @ Wing pro	Compilation of protein mutant data	遠伝研DDBJ	Japan	辞典	タンパク質, 変異		
Microbial Genome Workbench 提供サイト @	ゲノム配列が公開されているパクテリアおよび古緬菌を 対象とした遺伝子の検索や各種解析ツール	遺伝研分子遺伝研究系	Japan	プログラム	DNA, 配列,タ ンパク質, 配列	微生物 微生物 菌	
AAindex 提供サイト & Wing pro	Physicochemical properties of amino acids	ゲノムネット	Japan	知識モデル	タンパク質, ア ミノ酸特性		
PDBSTR 提供サイト @ Wing pro	タンパク質、核酸の立体構造データベース。	京大化研	Japan	プログラム	タンパク質,立		
GENES 提供サイト @ Wing pro	遺伝子のアミノ酸配列を蓄積したもの。	京大化研	Japan	プログラム	タンパク質, 配 , 列		
eF-site 提供サイト @ Wing pro	Electrostatic surface of Functional site: electrostatic potentials and hydrophobic properties of the active	大阪大学	Japan	プログラム	タンパク質, 立 ・ 体構造		

(途中略)	
or the active sites (画) 蛋白質および生体高分子の立体構造データベースと それに関連する二次データベース	新 11) 大阪大 ^会 究センタ
タンパク質の構造と機能について解説したもの。	大阪大学
Protein research foundation database of peptides: sequences, literature and unnatural amino acids	PRF(重
蛋白質と核酸の複合体構造を集めたデータベースで、 認識モチーフや構造型にしたがって分類	九工大(
	(画) 蛋白質および生体高分子の立体構造データベースとそれに関連する二次データベース タンパク質の構造と機能について解説したもの. Protein research foundation database of peptides: sequences, literature and unnatural amino acids 蛋白質と核酸の複合体構造を集めたデータベースで、

記載の順番には規則性は見られませんが、10番目ぐらいの順位で記載されている eProtS (タンパク質構造百科辞典) (画面 11) の提供サイトの文字をクリックすると、画面 12 が得られます。





タンパク質構造百科辞典

タンパク質構造百科辞典とは

eProts, タンパク質構造百科辞典とは、生物学的に重要なタンパク質を選び、その立体構造を表示 するとともに、タンパク質の専門家でない方にも利用していただけるように、日本語版と英語版が用意され ています。PDBjViewer という表示ソフトを使えてグ操作をリアルタイムで行うこともできます。(IE 5.0 or NN 6.0 以上推奨)

キーワードで検えする

キーワード アクチン

── ┌── ②クリックする

─ (画面 13)

チュートリアル ◆■■■ これをクリックするとタンパク質構造百科辞典の使用法が表示される。

関心のあるタンパク質の名前、例えばアクチンを入れると、キーワード の横の空白欄へ「ア クチン」 のように入力すると、検索結果の画面 13 が現れます。

検索結果

キーワード「 アクチン 」の検索結果です。

アドレス(D) 👸 http://eprots.protein.osaka-u.ac.jp/eProtS/KeywordSearch.do

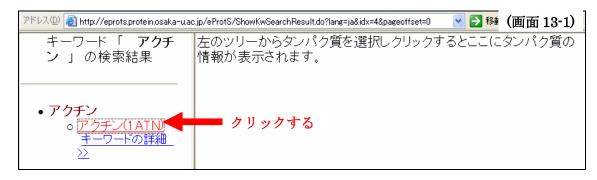
7 件のタンバク質がみつかりました。そのうち 1 件~ 7 件を表示しています。

- 1. <u>BMP2/BR1A複合体</u>
- BMP2/PRIARS ...
 DBI相同ドメイン
 Forminファミリー蛋白質(FH2ドメイン)/アクチン複合体
 Ta0583, 古細菌のアクチンホモログ
 アクチン
 クリックする

- 5. アクチン 6. ヒト心臓・トロポニン 7. ミオシンH鎖

・ップに戻る

アクチンをクリックすると、画面 13-1 が現れます。「左のツリーからタンパク質を選択 **しクリックするとここにタンパク質の情報が表示されます**」の表示に従って左の欄のアク チン(1ATN)をクリックするとアクチンの機能や高次構造、文献やそのタンパク質に関する 概要が得られます(画面14)。





画面 12 のチュートリアル (少数の生徒に教師が集中的に教える事、あるいは家庭教師による一対一の教育を意味します。教育用の書籍やビデオなどの各種メディア、あるいはその入門部分をチュートリアルという場合もある: ウィキペディアより) をクリックすると、この**タンパク質構造百科辞典**の使用法を学ぶことが出来ます。

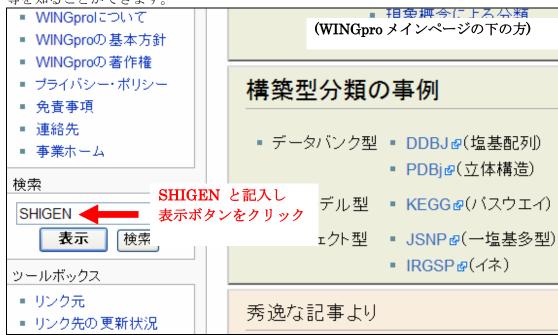
レポート課題 3) eProtS (タンパク質構造百科辞典) を用いて、アクチン以外のタンパク質について、その機能と高次構造を記載せよ。

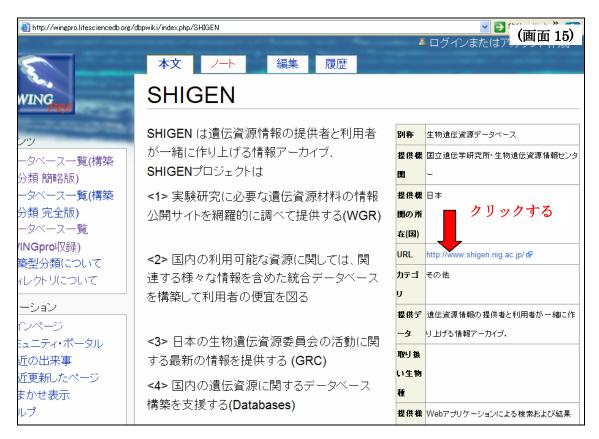
遺伝資源(生物材料)利用のためのデータベース類

生物材料を用いて実験的な研究を行う際、あるいは生物材料を産業的に活用する際には、信頼できる生物材料(例えば、細菌、ウイルス株、突然変異体、遺伝子クローン)を入手することが重要です。それぞれの生物材料、例えば突然変異体や遺伝子クローンの多くは、個々の研究者が作成した例が多いのですが、それらの生物材料を個々の研究者から提供を受けるよりは、それらを組織的に収集している機関を通じて提供を受ける場合が増えてきています。生物材料を生物資源(バイオリソース)としてとらえて、国家レベルで大規模に収集し、保存し、分与するシステムが整ってきています。しかしながら、生物の種類が多様であるだけに、専門的な知識を持った多数の研究グループが、分担しながら生物資源を収集・分与しており、その実態を把握することは容易ではありませんでした。現在では、多岐にわたった生物資源の所在や種類、分与方法等に関するデータベースが作成されていますので、我が国の生物資源に関するデータベースの例を紹介します。

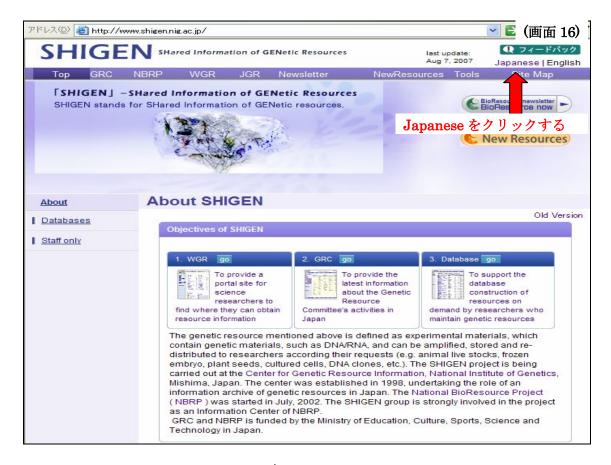
WINGpro の初期画面 (メインページ:画面 1) に戻って、左欄のコンテンツとナビゲーション欄のさらに下にある検索の下の空白欄へ SHIGEN と記入して、その下の表示の文字 (検索ボタン) をクリックすると、画面 15 が現れ SHIGEN (生物遺伝資源データベース) の目的

等を知ることができます。





右側の箱内のURLのhttp://www.shigen.nig.ac.jp/をクリックすると、画面16が現れます。



右上のフィードバックの下の Japanese | English において、Japanese を選択すると、日本語の説明文が得られます (画面 17)。



画面 17 の中央に近い 1. 世界の遺伝資源関連情報をクリックすると、画面 18 が現れ、個別のバイオリソース(生物遺伝資源、実験用生物材料)に関する情報を収集している情報公開サイトの一覧が表示されます。



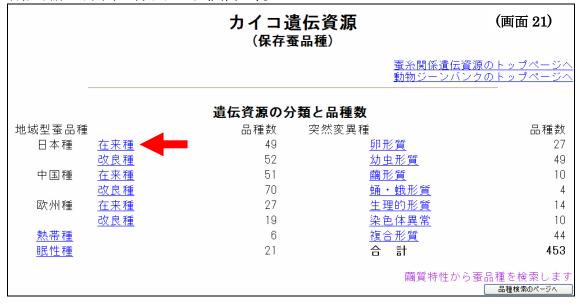
例えば、**動物**の欄の**カイコ**をクリックすると**画面 19** が現れ、カイコに関する情報を収集している情報公開サイトが得られます。



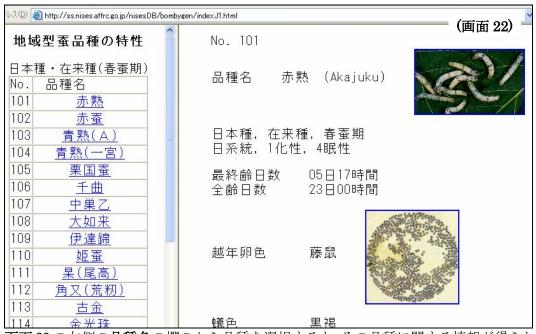
例えば、**カイコ遺伝資源データベース**をクリックすると、**画面 20** が現れ、括弧内の**保存蚕** 品種の横の GO をクリックすると、**画面 21** が現れます。



画面中の下線付きの青色文字の**在来種や改良種**等をクリックすると、各々のカイコ品種の特徴や繭の写真等が得られます(画面 22)。



(例)日本種 在来種を選択したときの画面



画面22の左側の品種名の欄のから品種を選択すると、その品種に関する情報が得られます。

レポート課題 4) 画面 18 において、カイコ以外の生物をどれかを選択して、わが国で作成されている情報公開サイトやデータベースがあれば、その情報公開サイトやデータベースの名称と、作成している機関や研究グループの名称を記載せよ。

データベースを利用しようとする場合、それを提供している機関の都合でサービスを一時的に停止していることがあります。さらには、同一な IP アドレスからの多数の同時アクセスがあると、そのサイトへの攻撃等の不正アクセスと提供機関側の計算機が判断して、その IP アドレスからのアクセスを拒否することもあります。長浜バイオ大から外部への通信では、同一の IP アドレスが割り当てられていますので、実習中にそのような不都合が起きることがあり得ます。その際は、一時その課題を中止して、次の課題へ進んでください。通常は、ある程度の時間を経過するとアクセスが可能になります。

複数のデータベースの統合的な利用: Jabion の利用

データベースはコンピュータを用いて作成していますので、大量のデータを収録でき、高機能な検索機能を持つ便利さだけでなく、定期的に更新すれば、最新の情報を提供することが可能になります。データベースの利用に際しては、複数のデータベースを関連づけながら統合的に利用することも重要になります。例えば、一つの病気に着目した場合に、その病気に関する事柄を理解した上で、その病気に関する遺伝子の配列情報を知り、その遺伝子から創られるタンパク質の高次構造をデータベースで参照し、多様な生物種の高次構造を比較することも可能になります。さらに、そのタンパク質に結合する能力を持つ分子を探索することは薬剤の設計(創薬)につながります。次にこの流れに沿った、データベースの統合的な利用の一部を実習します。

ここでは、日本語で利用できる日本語バイオポータルサイト(Jabion:画面 23: http://www.bioportal.jp/)を用いて、複数のデータベースの統合的な利用を試みます。Google 日本(http://www.google.co.jp/)で、"Jabion"を検索項目として検索しても、検索結果にJabion 日本語バイオポータルサイトが表示されます。



画面 23 の Jabion の文字の下のツールバーの**用語辞書**をクリックすると、**画面 24** が現れます。



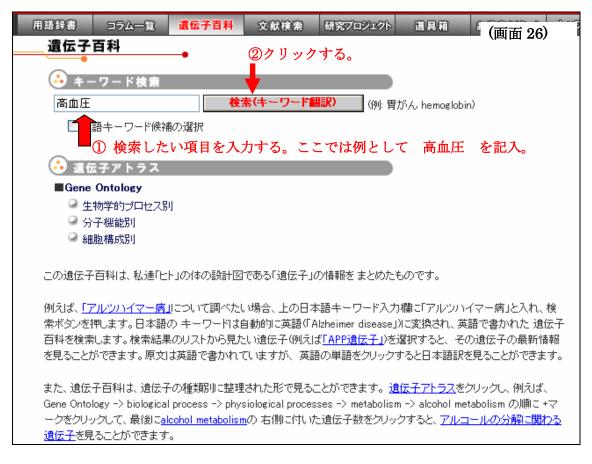
画面中央部のキーワード:の横の空白欄へ、検索項目を日本語で入力し(この例では 高

血圧 を入力した)、**検索**ボタンをクリックすると、その用語に関係した説明の**画面 25** が得られます。現時点では、この**用語辞書**の部分は作成の途中の段階に思え、充分とはいえませんが、その用語の意味の概要を知る上で便利です。

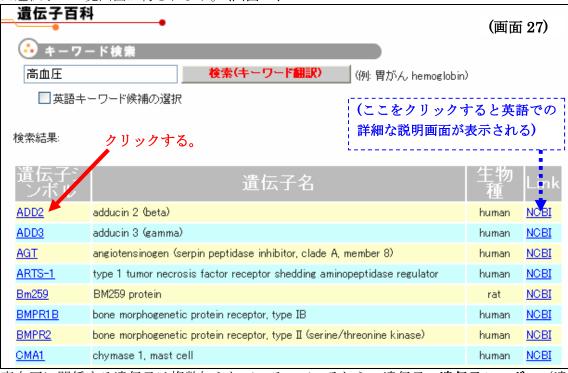


今回の実習で重要になるのは、**画面 23** の **Jabion** (http://www.bioportal.jp/)の文字の下のツールバーの遺伝子百科の部分で、遺伝子百科の部分をクリックすると**画面 26** が表示されます。





キーワード検索の下の空白欄へ検索項目を日本語で入力し(この例でも **高血圧** を入力した)、**検索(キーワード翻訳)**のボタンをクリックすると、その用語「**高血圧**」に関係した遺伝子の一覧画面が得られます。(画面 27)

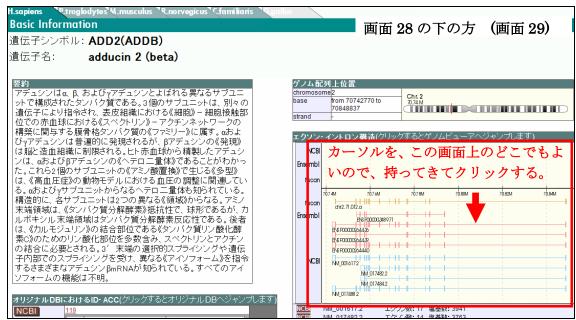


高血圧に関係する遺伝子は複数知られているので、それらの遺伝子の遺伝子シンボル(遺伝子名の略号)、遺伝子名、その遺伝子が知られて生物種名等を知ることが出来ます。遺伝子シンボルの下の遺伝子名の略号(例えば ADD2)をクリックすると、画面 28 が表示されます。

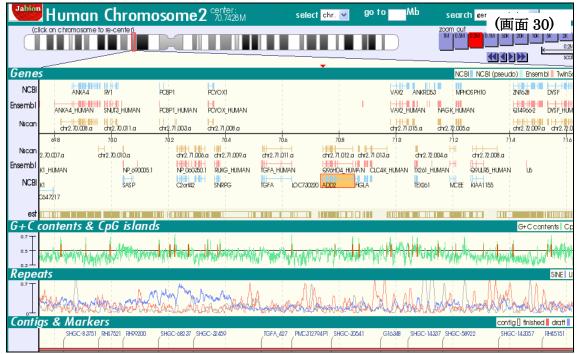
※画面 27 において、ADD2 の行の Link 欄の NCBI (米国の国立バイオテクノロジー情報センターの略称)をクリックすることでも、ADD2 に関する詳細情報を得ることが可能になりますが、全てが英語による説明なので、今回はこの機能は使いません。

ADD2 遺伝子に関する**画面 28** が現われます。この場合は遺伝子 ADD2 に関する日本語での要約を含む、この遺伝子の詳細情報を得ることが可能になります。





画面 28 を下へスクロールして得られる、日本語での**要約**を含む画面下の部分が**画面 29** です。ここには ADD2 遺伝子のゲノム配列上の位置が染色体(この場合はヒト2番染色体)上の位置まで図示された形式で表示され、エクソン・イントロン構造も表示されます(エクソンよりエキソンの方が一般的な名称)。エクソン・イントロン構造(クリックするとゲノムビューアへジャンプします)に従ってクリックすると、この遺伝子近傍のゲノム構造、例えば近傍の他の遺伝子の位置や、それらのさらに詳細な遺伝子構造が得られます(画面 30)。



画面30のGenesの下の欄には、異なった3つのゲノム情報解析機関(NCBI, Ensembl, N-scan)で推定している遺伝子が記載されていますが、3機関で同様な結果を推定している遺伝子は信頼性が高いと考えられます。ゲノム配列上の位置を数字で表示している横線の上側には、データベースに登録されている配列側がコーディング鎖となっている遺伝子類が記載され、横線の下側には逆鎖側がコーディング鎖となっている遺伝子類が記載されています。

画面 29 の要約の上の Basic Information の文字の上の H. sapiens (ヒト)や M. musculus (マウス) は生物種名を表します。画面 29 では H. sapiens が選択されており、ヒトの ADD2 に関する情報が記載されています。Basic Information の文字の上の行の M. musculus をクリックすると、マウスの ADD2 に関する情報に変わります (画面 31)。



ゲノム配列上の位置を見ると 6 番染色体に変わっているので、ADD2 はマウスの 6 番染色体上の位置することが分かる。

画面 29 (H. sapiens ヒトの ADD2) のオリジナル DB における ID・ACC の下の Ensembl の peptide ACC の下の番号が複数個ある場合には、選択的スプライシング等で複数の成熟 mRNA ができ、一種類の遺伝子から複数種類のタンパク質ができることを示しています。

NCBI	<u>119</u>	
	no. transcript ACC	peptide ACC
	1 <u>NM 001617.2</u>	NP 001608.1
	2 <u>NM 017482.2</u>	NP 059516.2
	3 <u>NM 017484.2</u>	NP 059518.2
	4 <u>NM 017488.2</u>	NP 059522.1
	5 <u>NM 017483.2</u>	NP 059517.1
Ensembl	ENSG00000075340	
	no. transcript ACC	peptide ACC
	1 ENSP00000348971	ENST00000356565
	2 ENSP00000264436	ENST00000264436
	3 ENSP00000264439	ENST00000264439
	4 ENSP00000264440	ENST00000345706
	5 ENSP00000264438	ENST00000349307
	6 ENSP00000347972	ENST00000355733
	chr2.71.012.a	

レポート課題 5) 画面 26 において、高血圧以外の病気名をキーワードとして用いて、その病気に関係する 2 種類の遺伝子を検索し、遺伝子シンボルと遺伝子名を記載せよ。次に、それらの遺伝子の一例に関して、ヒトの何番目の染色体に位置しているのかを、画面 28 のゲノム配列上の位置表示の形式で図示せよ。また得られた病気に関する遺伝子のどちらでも良いが、エクソン・イントロン構造を画面 28 のエクソン・イントロン構造の形式で図示して、エクソン部分とイントロン部分がどこであるのかを示せ。一般的に、エクソンとイントロンのどちらが長い配列なのかも述べよ。

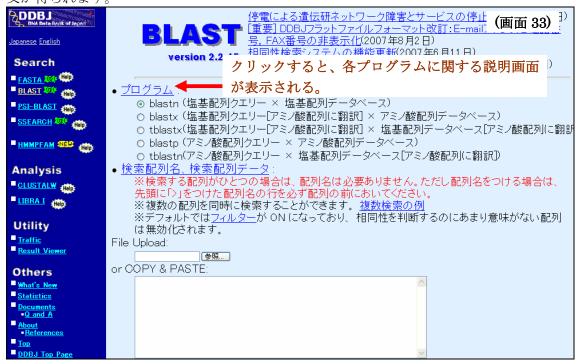
公的機関の高機能な計算機を用いた配列解析

国際 DNA データバンク(DDBJ/EMBL/GenBank)等の公的機関では、塩基配列ならびにアミノ酸配列の公開以外にも、これら配列についての多様な情報解析プログラムを公開しており、一般ユーザーによるこれら機関の高機能な計算機を用いた情報処理を可能にしています。

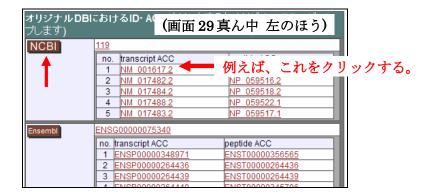
DDBJ(日本 DNA データバンク)の場合には、日本語による使用法の解説もあるので、初心者には特に便利です。**画面 32** は DDBJ の Home page です。(日本 DNA データバンク http://www.ddbj.nig.ac.jp/ Google で DDBJ と記入して検索しても、検索結果のトップに表示されます。)



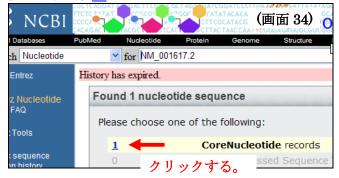
左側の欄の Search(検索)・Analysis(解析)の下に記載された下線付きの英語名は、キーワード検索や配列解析用のプログラム名です。例えば <u>BLAST</u> は配列相同性検索に使用される最も有名なプログラムです。この <u>BLAST</u> の文字をクッリクすると、**画面 33** が現れ、BLAST プログラムに関する日本語による簡単な使用説明があります。青文字で下線の付されたプログラムの文字をクリックすると、各プログラムに関するさらに詳しい日本語による説明文が得られます。



画面 33 の中央部の or COPY & PASTE: の下の空白欄へ配列を COPY & PASTE すれば、その配列と相同性の高い配列をデータベース中から探し出してくれます。画面 29(真ん中左のほう)の NCBI の transcript ACC の下の番号をクリックして、次の手順によって得られた、遺伝子の塩基配列を COPY & PASTE して下さい。



次のように、 $\underline{1}$ CoreNucleotide records が表示される。 $\underline{1}$ をクリックします。



次の画面の <u>MM 001617</u>をクリックします。

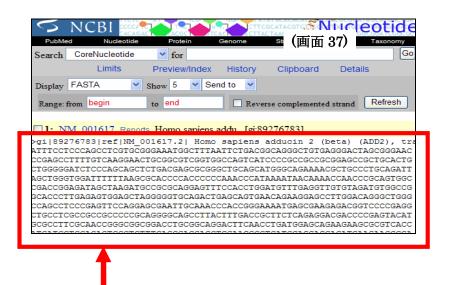


次のように、NM 001617 の Flat file の画面が表示されます。

Display の中の FASTA を選択すると、FASTA 形式の塩基配列情報が表示されます。



次の画面の、〉gi の行も含めて、塩基配列情報をコピーします。



コピーする。

Windows を使用の方は、赤色の線で囲まれた塩基配列を含む部分をドラッグした後に、マウスの右クリックをして、コピーを選び、画面 38 の貼り付けたい位置へカーソルを移してから、右クリックして貼り付けを選びます。

注)ブラウザを Internet Explorer (IE)を使用のかたは、上記の通りで問題ありあませんが、Netscape を使用の方は BLAST の結果が上手く表示されない場合があります。その場合は、>で始まるコメント行の余分なコメントを削除して、貼り付けた後のコメント行を1行に収めると上手く処理されます。

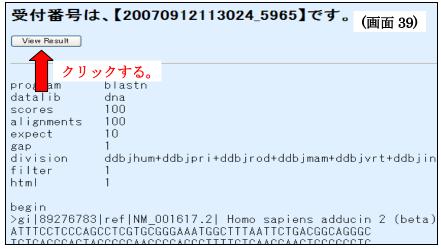
コピーした塩基配列を、画面 38 (画面 33 と同じ) の or COPY & PAST の欄に貼り付ける。



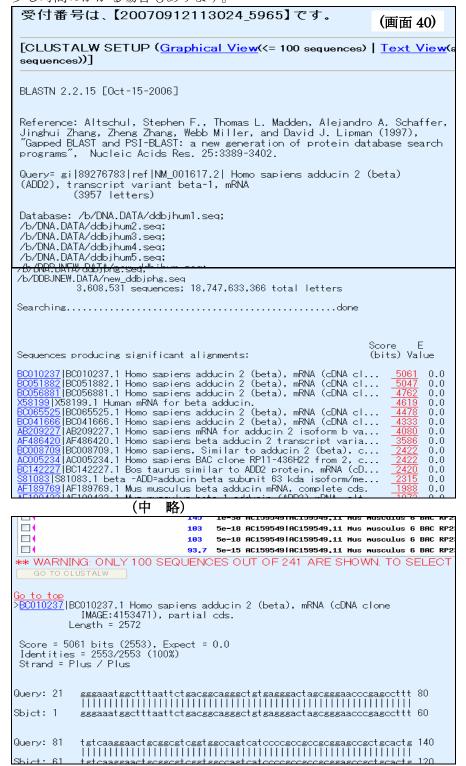
画面 38 で ・塩基配列データベースの下の

○ DDBJ 全データ(DDBJ 定期リリース + 新着データ) の○内を選択すれば、DDBJ 全塩基配列データを対象に、COPY & PASTE した塩基配列と配列の相同性(類似性)の高い配列を選び出してくれます。

長方形の括弧内の「**入力内容の送信」**のボタンをクリックすることで、相同性検索が開始され、 次の画面が表示されます。(画面 39)



「View Result」ボタンをクリックすると、配列相同性検索の結果が表示されます(画面 40)。 少し時間のかかる場合もあります。



検索対象 DIVISION: [DDBJ 全データ]、[DDBJ 新着データ] 選択時に有効ですの下の括弧で**ヒト**と**霊長類**のみを指定すれば、**ヒト**と**霊長類**の配列データセットのみに検索対象を限定できます(画面 41)。

CGACCGGAGATAGCTAAGATGCCGCGCAGGAGTTTCCACCTGGATGTTTGAGGTTGTGTAGATGTGGCC	
● 検索結果: (画面 41:画面 33 の下,画面 38 の下)	
WWW ☑Graphical View (<= 100 sequences)	
※WWW指定時にGraphical Viewをチェックすると、アラインメントがグラフィカルに表示されます	
○ E-Mail ☑ HTML format	
入力内閣の送信 入力項目の中止	
結果を E-Mail で受け取りたい場合は、こちらをクリックし、自分の E メールアドレノ	スチ
●検索対記入する。	
プログラムにより、選択できるアーメントへが乗なかより。	
■ 塩基配列データベース	
● DDBJ 全データ (DDBJ 定期リリース + 新着データ) クリックすると全てのチ]
対象にしたいものをクリックする。	
● <mark>検索対象DIVISION</mark> : [DDBJ全データ]、[DDBJ新着データ] 選択時で有効です	
チェックされたdivisionが検索対象になります <u>default select-all clear-all</u>	
□ヒト □霊長類 □齧歯類 □哺乳類 □脊椎動物 □無脊椎動物 □植物 □バクテリア □ウィルス □ファージ □未注釈データ □GSS	
□ HTG □特許データ □STS □ □合成配列 □HTC □ENV	
EST division select-all clear-all	
Lo I dividin general di cicar di	

COPY & PASTE した配列が長い場合や、検索対象 DIVISION が [DDBJ 全データ] のように検索対象が広範囲の場合、さらには DDBJ を多数の人が利用している場合等には、相同性検索の結果が得られるのに時間がかかります。画面 41 (画面 33 の下, 画面 38 の下)の検索結果:の下の 〇E-Mail の〇内を選び、E-Mail アドレスを括弧内に記載してから入力内容の送信の文字をクリックすれば、結果は E-Mail で送られて来ます。研究を目的とした解析では、データの整理をする上で E-Mail を用いる方が便利です。

レポート課題 6) 画面 29 の中央部の NCBI の下の peptide ACC の下の番号をクリックすると、タンパク質のアミノ酸配列が得られる。画面 32 と画面 33 の選択項目をどのように変更すれば、このアミノ酸配列と相同性の高いタンパク質配列を探し出せるかを記載せよ。

レポート課題 7)レポート課題 5 で選択した病気に関する 2 種類の遺伝子について、その遺伝子由来のタンパク質と相同性の高いアミノ酸配列を持つタンパク質配列類を、齧歯類(げっし類:ネズミ目(Rodentia)でリス、ネズミ、ヤマアラシなどが含まれる)を対象に検索し、検索結果を E-Mail で取得して画面 40 の形式で記載せよ。なお結果が A4 用紙で 3 枚を超える際は、3 枚分を提出せよ。

余裕のある人への追加課題)

画面 42 と **43** は、遺伝資源に関するデータベースを公開しているサイトです。多くのデータベースは日本語での使用が可能です。興味のある遺伝資源に関するデータベースにアクセスして、そのデータベースに関する印象と、何故その遺伝資源のデータベースに興味を持ったのかを記載せよ。

文部科学省 ナショナルバイオリソースプロジェクト

(URL http://www.nbrp.jp/index.jsp) Google で NBRP を検索しても出てきます。



「日本の遺伝資源情報」をクリックすると次の画面が表示されます。



<レポート課題>

レポート課題 1) Avibase を用いて、かもめ以外の鳥を自分で設定して、その鳥の学術名と map (生息域) と image (写真)を記載せよ。

レポート課題 2) 物質概念による分類の DNA と RNA の各々の項目について、何種類のデータベースが収録されているかを記載せよ。

レポート課題 3) eProtS (タンパク質構造百科辞典) を用いて、アクチン以外のタンパク質について、その機能と高次構造を記載せよ。

レポート課題 4) 画面 18 において、カイコ以外の生物をどれかを選択して、わが国で作成されている情報公開サイトやデータベースがあれば、その情報公開サイトやデータベースの名称と、作成している機関や研究グループの名称を記載せよ。

レポート課題 5) 画面 26 において、高血圧以外の病気名をキーワードとして用いて、その病気に関係する 2 種類の遺伝子を検索し、遺伝子シンボルと遺伝子名を記載せよ。次に、それらの遺伝子の一例に関して、ヒトの何番目の染色体に位置しているのかを、画面 28 のゲノム配列上の位置表示の形式で図示せよ。また得られた病気に関する遺伝子のどちらでも良いが、エクソン・イントロン構造を画面 28 のエクソン・イントロン構造の形式で図示して、エクソン部分とイントロン部分がどこであるのかを示せ。一般的に、エクソンとイントロンのどちらが長い配列なのかも述べよ。

レポート課題 6) 画面 29 の中央部の NCBI の下の peptide ACC の下の番号をクリックすると、 着目タンパク質のアミノ酸配列が得られる。 画面 32 と画面 33 の選択項目をどのように変 更すれば、このアミノ酸配列と相同性の高いタンパク質配列を探しだせるかを記載せよ。

レポート課題 7) レポート課題 5 で選択した 2 種類の遺伝子に関して、その遺伝子由来のタンパク質と相同性の高いアミノ酸配列を持つタンパク質配列を、齧歯類(げっし類:ネズミ目(Rodentia)でリス、ネズミ、ヤマアラシなどが含まれる)を対象に検索し、検索結果を画面 40 の形式で記載せよ。なお結果が A4 用紙で 3 枚を超える際は、3 枚分を提出せよ。

レポート課題 8) 課題 $5\sim7$)で使用したアミノ酸配列のどちらか一方を用いて、【脊椎動物、無脊椎動物、バクテリア】の各々のカテゴリーを検索対象のデータベースとして別々に選択し、BLAST プログラム(tblastn)による相同性検索を実施せよ。このとき相同性が得られた配列の中で e-value が「 $1e^{-10}$ 」以下のものがあった場合、この相同性が見られた配列の生物種名を記載せよ。なお、一個のカテゴリーのデータベースについて、 $1e^{-10}$ 以下の検索結果が 5 件以上あった場合には、そのカテゴリーのデータベースについては上位 5 件の結果のみで良い。得られた検索結果をもとに、どの程度の生物系統にまでこの着目遺伝子の進化的な保存関係が存在しているのかを考察せよ。なお、この場合の e-value は、相同性検索に用いていた塩基配列の相互間で、類似配列が偶然に生じたと仮定した場合のその出現確率を意味している。e-value が「 $1e^{-10}$ 」以下であれば、偶然にこれらの似た配列が出現する確率が極めて低いので、進化的に共通の遺伝子配列から由来したことを示している。

生物種名を調べるためのヒント: DDBJ から得られるフラットファイル中【ORGANISM】行に生物種名(学術名)が記載されている。日本語への変換は、取得した生物種名を使いインターネット検索を行うとよい。

レポート課題 9) 今までの実習課題では、日本語の使えるデータベースを使用してきた。しかしながら、目的とする情報を得るためのデータベースで日本語が使えない場合も多い。そのデータベースの使用法に関する英文の説明文 (Announcement や README) を参照して使用する必要がある。その具体例として、課題 9) では Codon Usage (遺伝暗号使用)に関するデータベースを使用する。遺伝暗号(Codon)の使用パターンには生物種に関する特徴があり、同一の生物種(特に同一の微生物種の場合)の遺伝子類の同義コドンの使用パターンがかなり似ている。興味深いことに、異なった生物種間ではその同義コドンの使用パターンが異なっている。この性質は、ゲノム配列が解読された際に、得られた多数の ORF (Open Reading Frame)の内で、どれが本物の遺伝子であるのかを情報学的に知る上での指針となる。この意味からも、各生物種の Codon Usage (遺伝暗号使用)パターンを知ることはゲノム研究において重要である。Codon Usage (遺伝暗号使用)に関するデータベースでは、各生物種別にその時点で知られている全遺伝子の遺伝暗号使用回数を集計して、千分率としてその生物種の Codon Usage (遺伝暗号使用)の特徴パターンの指標として公開している。

ここでは、課題 8)で見つけた生物種名について、【脊椎動物、無脊椎動物、バクテリア】の3カテゴリーについて、各カテゴリー別に3つの生物種を選び、その生物種のCodon Usage (遺伝暗号使用)の特徴を以下のようにして知る(無脊椎動物やバクテリアで見つかっていなければ、その部分は省略せよ)。まず「WINGpro」の検索機能を使用して、「遺伝暗号」に関するデータベースを探し出し、そこでの Announcement の文章を参考にして、上記の生物種ごとに遺伝暗号頻度表を取得せよ。次に【脊椎動物、無脊椎動物、バクテリア】のカテゴリー間とカテゴリー内の生物種の遺伝暗号頻度表を比較して、どちらで類似性が高いかを考察せよ。

レポート課題 10) 以下のいずれかについて記述せよ。

- ① 現在、公開されているバイオ分野のデータベース (データ資源や生物資源) を用いて、 自分が行ってみたい、あるいは関ってみたい研究について
- ② バイオ分野において、どのようなデータベースがあればよいか

余裕のある人への追加課題 1)

画面 42 と **43** は、遺伝資源に関するデータベースを公開しているサイトです。多くのデータベースは日本語での使用が可能です。興味のある遺伝資源に関するデータベースにアクセスして、そのデータベースに関する印象と、何故その遺伝資源のデータベースに興味を持ったのかを記載せよ。

余裕がある人への追加課題2)

遺伝子の発現レベルを知ることは、遺伝子間の制御やそれらの間の相互作用などに関わる生命現象を知る上で重要となる。【ヒト統合ボディーマップ】 (http://okubolab.genes.nig.ac.jp/bodymap_i/)は、ヒト遺伝子の臓器や組織別の遺伝子発現パターンを収録した統合サイトです。レポート課題5にて記述した遺伝子シンボルを用いて、その着目遺伝子がどの組織で発現が高いのかを調べ、記述し図示せよ。他に同じ組織で発現している遺伝子についても調べて、記述せよ。

以上